


ΔΙΚΤΥΟ RBF

Αρχιτεκτονική δικτύου RBF

- Δίκτυα RBF: δίκτυα συναρτήσεων πυρήνα (radial basis function networks). Πρόσθιας τροφοδότησης (**feedforward**) για **προβλήματα μάθησης με επίβλεψη**. Εναλλακτικό του MLP.
- Υλοποιούν απεικονίσεις από το χώρο εισόδων στο χώρο εξόδων (όπως το MLP), ωστόσο η λειτουργία των νευρώνων του κρυμμένου επιπέδου είναι εντελώς διαφορετική.



Αρχιτεκτονική δικτύου RBF

- Τα δίκτυα RBF έχουν **ένα μόνο κρυμμένο επίπεδο**, του οποίου οι κρυμμένοι νευρώνες j υπολογίζουν μια ειδική συνάρτηση $h_j(\mathbf{x})$ του διανύσματος εισόδου \mathbf{x} .
- Εστω ένα δίκτυο RBF με d εισόδους, M κρυμμένους νευρώνες και p εξόδους. Για είσοδο $\mathbf{x}=(x_1, \dots, x_d)^T$, οι έξοδοι o_i ($i=1, \dots, p$) του δικτύου υπολογίζονται ως:

$$o_i(\mathbf{x})=v_{i0}+\sum_{j=1}^M v_{ij}h_j(\mathbf{x})$$

v_{ij} είναι το βάρος της σύνδεσης από τον κρυμμένο νευρώνα j προς το νευρώνα εξόδου i και v_{i0} είναι η πόλωση του νευρώνα εξόδου i .

- **Οι νευρώνες εξόδου** είναι τυπικοί **νευρώνες εσωτερικού γινομένου** (όπως και στο MLP) με **γραμμική** συνάρτηση ενεργοποίησης.


Συναρτήσεις RBF

- Οι κρυμμένοι νευρώνες υπολογίζουν τις συναρτήσεις $h(x)$ (με όρισμα το διάνυσμα εισόδου x) που ονομάζονται **ακτινικές συναρτήσεις βάσης** (radial basis functions).
- Συνήθως έχουν την ακόλουθη μορφή: υπάρχει κάποιο σημείο (που ονομάζεται **κέντρο**) για το οποίο παρέχουν μέγιστη τιμή και καθώς απομακρυνόμαστε **ακτινικά** από το κέντρο η τιμή της συνάρτησης μειώνεται και σχεδόν εκμηδενίζεται για σημεία x που είναι μακριά από το κέντρο.
- Χαρακτηριστικό παράδειγμα είναι η συνάρτηση Gauss, που είναι γνωστή και ως **πυρήνας RBF (RBF kernel)**:

$$h_j(x) = \exp\left(-\frac{\|x - w_j\|^2}{2\sigma_j^2}\right) = \exp\left(-\frac{\sum_{l=1}^d (x_l - w_{jl})^2}{2\sigma_j^2}\right)$$

Συναρτήσεις RBF

- Το διάνυσμα βαρών $w_j = (w_{j1}, \dots, w_{jd})^T$ καθορίζει το **κέντρο** της συνάρτησης, ενώ η παράμετρος σ_j καθορίζει την **ακτίνα** της συνάρτησης.
- Παίρνει τη μέγιστη τιμή στο κέντρο (για $x = w_j$) και η τιμή ελαττώνεται εκθετικά καθώς απομακρυνόμαστε ακτινικά από το κέντρο.
- Ο ρυθμός μείωσης καθορίζεται από την τιμή της ακτίνας σ_j . Για μικρές τιμές της ακτίνας ο ρυθμός μείωσης είναι μεγάλος, ενώ το αντίθετο συμβαίνει για μεγάλες τιμές της ακτίνας.



$d=2$

Συναρτήσεις RBF

- Εντοπισμένες συναρτήσεις (local functions): χαρακτηρίζονται από μια **περιοχή εμβέλειας**, έξω από την οποία η συνάρτηση δίνει αμελητέες τιμές.
- Στην περίπτωση RBF, η περιοχή εμβέλειας είναι σφαιρική στις δύο διαστάσεις και γενικότερα **υπερσφαίρα** στις d διαστάσεις.
- Επομένως όταν ένα διάνυσμα εισόδου x εμφανίζεται ως είσοδος στο δίκτυο RBF, θα δώσουν μεγάλη τιμή εξόδου οι κρυμμένοι νευρώνες οι οποίοι περιέχουν το x στην περιοχή εμβέλειάς τους.
- Μπορούμε λοιπόν να θεωρούμε ότι **οι κρυμμένοι νευρώνες του δικτύου RBF ορίζουν σφαιρικές περιοχές επιρροής στον d -διάστατο χώρο των εισόδων.**

Δίκτυο RBF (ευθύ πέρασμα)

- Εστω ένα δίκτυο RBF με d εισόδους, M κρυμμένους νευρώνες τύπου RBF, και p εξόδους. Για κάποια είσοδο $x=(x_1,\dots,x_d)^T$, οι έξοδοι o_i προκύπτουν ως εξής:

– Επίπεδο εισόδου: $y_i^{(0)}=x_i, i=1,\dots,d$

– Κρυμμένο επίπεδο:

$$u_i^{(1)}=\sum_{j=1}^d (y_j^{(0)}-w_{ij})^2=\sum_{j=1}^d (x_j-w_{ij})^2, i=1,\dots,M$$
$$h_i=e^{-u_i^{(1)}/\sigma_i^2}, i=1,\dots,M$$

– Επίπεδο εξόδου:

$$u_i^{(2)}=v_{i0} + \sum_{j=1}^M v_{ij}h_j, i=1,\dots,p$$
$$y_i^{(2)}=u_i^{(2)} \quad i=1,\dots,p$$

– Έξοδος του δικτύου: $o_i=y_i^{(2)} \quad i=1,\dots,p$

Δίκτυο RBF

Ερώτηση: Δίνονται τρεις συναρτήσεις RBF $h_1(x)$, $h_2(x)$, $h_3(x)$ στο χώρο R^2 με κέντρα $(0,0)$, $(5,5)$, $(-5,-5)$ αντίστοιχα και $\sigma=1$ και για τις τρεις συναρτήσεις. Χωρίς να κάνετε υπολογισμούς, να εκτιμήσετε ποια από τις τρεις συναρτήσεις θα δώσει μεγάλη έξοδο για τα ακόλουθα δεδομένα εισόδου:

α) $x=(0.2,-0.2)$

β) $x=(-4.6,-5.2)$

γ) $x=(5.5,4.8)$


δ) $x=(-5,5)$

Δυνατότητες δικτύου RBF

- Το δίκτυο RBF (όπως και το MLP) χαρακτηρίζεται από την ιδιότητα της **παγκόσμιας προσέγγισης** (universal approximation).
- Η ιδιότητα αυτή μας εξασφαλίζει ότι ένα δίκτυο RBF μπορεί να προσεγγίσει οποιαδήποτε συνάρτηση με οποιαδήποτε ακρίβεια, αυξάνοντας επαρκώς τον αριθμό των νευρώνων RBF.
- Ωστόσο αυτή η ιδιότητα δεν είναι πρακτικά εκμεταλλεύσιμη, διότι δεν μας προτείνει πόσους RBF νευρώνες να χρησιμοποιήσουμε δοθέντος ενός συνόλου παραδειγμάτων εκπαίδευσης.
- **Για πρόβλημα της επιλογής του αριθμού των νευρώνων RBF χρησιμοποιούνται οι μέθοδοι που αναφέρθηκαν για το MLP.**

Κατασκευή δικτύου RBF


- Έστω ότι γνωρίζουμε πως τα δεδομένα εκπαίδευσης ενός προβλήματος ταξινόμησης σχηματίζουν σφαιρικές (κατά προσέγγιση) και **διακριτές** ομάδες, και τα δεδομένα κάθε ομάδας είναι της ίδιας κατηγορίας.



Κατασκευή δικτύου RBF

- Για κάθε ομάδα δεδομένων, μπορούμε να ορίσουμε **ένα νευρώνα RBF** με κέντρο το κέντρο της αντίστοιχης ομάδας και ακτίνα τη διασπορά της ομάδας.
- Για κάποια είσοδο x η τιμή της εξόδου $h_j(x)$ του νευρώνα j δηλώνει εάν το x ανήκει στην ομάδα j . Έτσι το δεδομένο εισόδου x απεικονίζεται στο διάνυσμα $h(x)=(h_1(x),\dots,h_M(x))^T$, που δείχνει το βαθμό στον οποίο το x ανήκει σε κάποια από τις ομάδες.
- Στη συνέχεια είναι πολύ εύκολο να καθορίσουμε τα βάρη στο επίπεδο εξόδου, ώστε ο κρυμμένος νευρώνας που αντιστοιχεί στην ομάδα κατηγορίας C_k να 'διεγείρει' μόνο τον αντίστοιχο νευρώνα εξόδου k .

Κατασκευή δικτύου RBF για το XOR



- Θεωρούμε **ένα κρυμμένο νευρώνα για κάθε παράδειγμα εκπαίδευσης**.
- Κάθε νευρώνας έχει για κέντρο ένα από τα τέσσερα παραδείγματα $(0,0)$, $(0,1)$, $(1,0)$ και $(1,1)$ και μια μικρή ακτίνα σ (π.χ $\sigma=0.1$).
- Κατά συνέπεια όταν κάποιο από τα παραδείγματα εμφανιστεί ως είσοδος θα δώσει μεγάλη έξοδο μόνο ο αντίστοιχος κρυμμένος νευρώνας.

Κατασκευή δικτύου RBF για το XOR

- Στη συνέχεια θα πρέπει να καθορίσουμε τα **βάρη από το κρυμμένο επίπεδο προς το επίπεδο εξόδου**.
- Δεδομένου ότι έχουμε δύο κατηγορίες C_1 και C_2 θα θεωρήσουμε δύο γραμμικές εξόδους o_1 και o_2 μία για κάθε κατηγορία.
- Το διάνυσμα των εξόδων θέλουμε να είναι $(0,1)$ για τα διανύσματα $h=(0,1,0,0)$ και $h=(0,0,1,0)$ και $(1,0)$ για τα διανύσματα $h=(1,0,0,0)$ και $h=(0,0,0,1)$.
- Αυτή η απαίτηση επιτυγχάνεται εύκολα εάν θέσουμε:

$$\begin{array}{ll} v_{11} = 1, v_{21} = 0, & v_{14} = 1, v_{24} = 0 \\ v_{12} = 0, v_{22} = 1, & v_{13} = 0, v_{23} = 1 \end{array}$$

Εκπαίδευση δικτύου RBF

- Οι παράμετροι (βάρη) του δικτύου RBF που πρέπει να καθοριστούν κατά τη διάρκεια της εκπαίδευσης:
 - τα **κέντρα** $\mathbf{w}_j = (\mathbf{w}_{j1}, \dots, \mathbf{w}_{jd})^T$ ($M \cdot d$ παράμετροι) και οι **ακτίνες** σ_j (M παράμετροι) **των νευρώνων RBF**
 - τα **βάρη** \mathbf{v}_{ij} ($(M+1) \cdot r$ παράμετροι συμπεριλαμβανομένων των r πολώσεων \mathbf{v}_{i0}).
- Διαφορετική 'σημασία-ερμηνεία':
 - τα **βάρη** \mathbf{w} αναπαριστούν τις **συντεταγμένες των κέντρων** των κρυμμένων νευρώνων
 - τα **βάρη** \mathbf{v} έχουν την τυπική σημασία των νευρώνων εσωτερικού γινομένου (όπως και στο MLP) και **ορίζουν την εξίσωση υπερεπιπέδου για τους νευρώνες εξόδου**.
- Μπορεί να χρησιμοποιηθεί διαφορετική εκπαίδευση για τα δύο είδη βαρών.

Εκπαίδευση δικτύου RBF

- Όπως και στο MLP γίνεται μέσω της ελαχιστοποίησης του τετραγωνικού σφάλματος μεταξύ πραγματικών και επιθυμητών εξόδων του δικτύου.
- Έστω σύνολο παραδειγμάτων εκπαίδευσης $D=\{(x^n, t^n)\}$, $n=1, \dots, N$, $x^n=(x_{n1}, \dots, x_{nd})^T$ και $t^n=(t_{n1}, \dots, t_{np})^T$
- Το δίκτυο RBF θα πρέπει να έχει d νευρώνες στο επίπεδο εισόδου και p νευρώνες στο επίπεδο εξόδου. Εστω M ο αριθμός των κρυμμένων νευρώνων RBF (δίνεται από τον χρήστη).
- $\theta=(\theta_1, \dots, \theta_L)^T$ ($L=(M+1)(d+p)$) ένα διάνυσμα στο οποίο συγκεντρώνουμε όλες τις παραμέτρους του δικτύου
- $o(x^n; \theta)$ το διάνυσμα εξόδου του δικτύου RBF όταν το διάνυσμα εισόδου είναι το x^n . Επομένως μπορούμε να ορίσουμε την **τετραγωνική συνάρτηση σφάλματος**:

Εκπαίδευση δικτύου RBF

- **Τετραγωνική συνάρτηση σφάλματος:**

$$E(\theta) = \sum_{n=1}^N E^n(\theta), \quad E^n(\theta) = \frac{1}{2} \|t^n - o(x^n; \theta)\|^2 = \frac{1}{2} \sum_{m=1}^p (t_{nm} - o_m(x^n; \theta))^2$$

– $E^n(\theta)$ το τετραγωνικό σφάλμα ανά παράδειγμα (x^n, t^n)

- Δύο μεθοδολογίες εκπαίδευσης:
 - Ενιαία εκπαίδευση
 - Εκπαίδευση δύο σταδίων

Ενίαια Εκπαίδευση δικτύου RBF

- Μέθοδος **gradient descent** για ελαχιστοποίηση του $E(\theta)$ ως προς τις παραμέτρους θ_i του δικτύου.

$$\theta_i(t+1) = \theta_i(t) - \eta \frac{\partial E}{\partial \theta_i} \rightarrow \theta_i(t+1) = \theta_i(t) - \eta \sum_{n=1}^N \frac{\partial E^n}{\partial \theta_i}, \quad i=1, \dots, L$$

- Για το παράδειγμα (x^n, t^n) : $E^n = \frac{1}{2} \sum_{i=1}^p (o_i - t_{ni})^2$

$$h_j(x) = \exp\left(-\frac{\|x^n - w_j\|^2}{2\sigma_j^2}\right) = \exp\left(-\frac{\sum_{l=1}^d (x_l^n - w_{jl})^2}{2\sigma_j^2}\right) \quad o_i = v_{i0} + \sum_{j=1}^M v_{ij} h_j(x^n), \quad i=1, \dots, p$$

- Οπότε: $\frac{\partial E^n}{\partial v_{ij}} = (o_i - t_{ni}) h_j(x^n) \quad \frac{\partial E^n}{\partial v_{i0}} = (o_i - t_{ni})$

$$\frac{\partial E^n}{\partial w_{jl}} = \sum_{i=1}^p (o_i - t_{ni}) v_{ij} h_j(x^n) \frac{(x_{nl} - w_{jl})}{\sigma_j^2} \quad \frac{\partial E^n}{\partial \sigma_j} = \sum_{i=1}^p (o_i - t_{ni}) v_{ij} h_j(x^n) \frac{\|x_n - w_j\|^2}{2\sigma_j^3}$$

Ενίαια Εκπαίδευση δικτύου RBF

- Μπορεί να εφαρμοστεί gradient descent με ομαδική ή σειριακή ενημέρωση. Προτιμάται η ομαδική ενημέρωση.
- Τα βάρη v_{ij} αρχικοποιούνται όπως στο MLP: τυχαία στο $(-1,1)$.
- Αν τα κέντρα και οι ακτίνες των συναρτήσεων βάσης αρχικοποιούνται εντελώς τυχαία, είναι πολύ δύσκολο για τη μέθοδο gradient descent να αποφύγει **ρηχά** τοπικά ελάχιστα.
- Στην περίπτωση όμως, που τα κέντρα και οι ακτίνες έχουν αρχικοποιηθεί σε καλές τιμές, τότε βρίσκουμε καλές λύσεις.
- Μια πιο αποδοτική προσέγγιση αρχικού καθορισμού των κέντρων βασίζεται στην παρατήρηση ότι **επιθυμούμε τα κέντρα των νευρώνων RBF να τοποθετούνται σε κέντρα ομάδων** που υπάρχουν στα δεδομένα εκπαίδευσης. Έτσι προέκυψε η **μέθοδος εκπαίδευσης των δύο σταδίων**.

Εκπαίδευση δύο σταδίων δικτύου RBF

Πρώτο στάδιο:

- Χρησιμοποιείται το σύνολο των δεδομένων εκπαίδευσης $X=\{x^n\}$ για τον καθορισμό νευρώνων RBF.
- Αγνοείται η πληροφορία σχετικά με την κατηγορία κάθε προτύπου εκπαίδευσης.
- **Εφαρμόζεται κάποια μέθοδος ομαδοποίησης**, π.χ. k-means ή LVQ. Προκύπτουν άμεσα τα κέντρα των ομάδων w_j ενώ ο καθορισμός της ακτίνας γίνεται υπολογίζοντας τη διασπορά των δεδομένων κάθε ομάδας:

$$\sigma_j^2 = \frac{1}{N_j} \sum_{x^n \in O_j} \|x^n - w_j\|^2$$


Εκπαίδευση δύο σταδίων δικτύου RBF

Δεύτερο στάδιο:

- 1^η επιλογή
 - Τα w_{ij} και σ_j παραμένουν σταθερά στις τιμές που καθορίστηκαν από το πρώτο στάδιο. Απομένει ο η εύρεση των βαρών v_{ij} και των πολώσεων v_{i0} του επιπέδου εξόδου.
 - Το πρόβλημα ανάγεται στην εκπαίδευση με το **νέο σύνολο εκπαίδευσης** $\{(h^n, t^n)\}$ $h^n = (h_1(x^n), \dots, h_M(x^n))^T$
 - Μέθοδος gradient descent με μερικές παραγώγους
$$\frac{\partial E^n}{\partial v_{i0}} = (o_i - t_{ni}) \quad \frac{\partial E^n}{\partial v_{ij}} = (o_i - t_{ni}) h_j(x^n)$$
- 2^η επιλογή
 - Εφαρμογή gradient descent (όπως ακριβώς στην ενιαία εκπαίδευση), αρχικοποιώντας τα κέντρα και τις ακτίνες στις τιμές που προκύπτουν από το πρώτο στάδιο.

Παράδειγμα

Εκπαιδευμένο RBF για διάφορες τιμές του M




Σύγκριση MLP και RBF

- Υλοποιούν μη γραμμικές απεικονίσεις από το χώρο των εισόδων R^d στο χώρο των εξόδων R^p . Χαρακτηρίζονται από την ιδιότητα της **παγκόσμιας προσέγγισης**.
- **Θεμελιώδης διαφορά:** στη μορφή των συναρτήσεων $h_j(x)$ του κρυμμένου επιπέδου.
- Κάθε κρυμμένος νευρώνας του MLP ορίζει την εξίσωση ενός υπερεπιπέδου: το MLP υλοποιεί συναρτήσεις ταξινόμησης **διαχωρίζοντας το χώρο των προτύπων με υπερεπίπεδα** και ορίζοντας τις **περιοχές απόφασης ως τομές των υπερεπιπέδων**.
- Στον υπολογισμό μιας εξόδου συμμετέχουν όλες οι κρυμμένες μονάδες: **κατανεμημένη αναπαράσταση**, δηλαδή η γνώση σχετικά με την έξοδο που αντιστοιχεί σε κάποια είσοδο κατανέμεται στις τιμές των βαρών όλων των κρυμμένων

Σύγκριση MLP και RBF

- Τα δίκτυα RBF δημιουργούν **τοπικές αναπαραστάσεις**, δηλαδή η γνώση σχετικά με την έξοδο που αντιστοιχεί σε κάποια είσοδο x ενσωματώνεται στα βάρη εκείνων των κρυμμένων νευρώνων οι οποίες περιλαμβάνουν το πρότυπο x στη σφαίρα επιρροής τους.
- Δίκτυα RBF: **ο χώρος παραδειγμάτων διαιρείται σε σφαιρικές περιοχές**, καθεμιά από τις οποίες αντιστοιχεί σε μια μονάδα του κρυμμένου επίπεδου.



Σύγκριση MLP και RBF

- Άλλες διαφορές:
 - Στο MLP μπορούμε να έχουμε περισσότερα του ενός κρυμμένα επίπεδα, ενώ το RBF έχει ακριβώς ένα κρυμμένο επίπεδο.
 - Το MLP εκπαιδεύεται με ενιαίο τρόπο (δηλαδή ενημερώνονται όλα τα βάρη με τον ίδιο αλγόριθμο), ενώ στο RBF έχουμε συνήθως εκπαίδευση δύο σταδίων με διαφορετικούς αλγορίθμους σε κάθε στάδιο.